

Predição de Consumo de Energia Elétrica em Ambiente de Smart Campus Utilizando Redes Neurais LSTM

Lucas M. Soares, Matheus C. Rodrigues, Leonardo Magalhães, Fernando C. Paiva
Prof.(a) Dr.(a) Carolina Toledo Ferraz

Motivação e Objetivo

A crescente demanda por energia elétrica em campus universitários gera padrões de consumo complexos, dificultando a identificação de ineficiências. Modelos lineares tradicionais falham em capturar dependências temporais, tornando as redes LSTM a alternativa mais robusta para esse contexto.

Objetivo Geral: Desenvolver e avaliar um modelo baseado em redes LSTM para prever, em horizonte de 24 horas, o consumo elétrico horário em edificações de campus universitário e avaliar o erro de previsão como mecanismo de detecção de anomalias, a fim de contribuir economicamente, ambientalmente e operacionalmente.

Metodologia

Base de dados: Dois edifícios da Universidade de Valladolid (Espanha): Edifício A (administrativo) e Edifício B (uso misto). Dados horários de jan/2016 a dez/2020 e variáveis climáticas da base NASA POWER.

Pré-processamento: Tratamento de duplicatas (horário de verão), interpolação linear de ausentes (<0,3%), correção de erros e criação de features cíclicas (seno/cosseno) para hora, dia e mês.

Modelo LSTM: Entrada 25h × 12 features → LSTM (128) → Dropout (20%) → LSTM (64) → Dropout (20%) → Dense(24h). Otimizador Adam, EarlyStopping.

Divisão: Treino 2016-2018 | Teste 2019 | Métricas: R², RMSE, MAE, MAPE.




Figura 1 - Fluxograma metodologia da pesquisa

Fonte: Elaborado pelos autores (2026)

Resultados Preliminares

Edifício A (administrativo): R² = 0,8057 | RMSE = 31,31 kWh | MAPE = 11,34% (benchmark: 10,18%, Δ = 1,16 p.p.)

Edifício B (uso misto): R² = 0,7989 | RMSE = 13,91 kWh | MAPE = 11,44% (Δ = 1,26 p.p.)

O MAPE equivalente entre os dois edifícios (~11,4%) comprova que o modelo generaliza para diferentes perfis de uso. O R² ≥ 0,79 indica que mais de 79% da variância do consumo é explicada pelo modelo.




Figura 2 - Consumo real vs previsto pelo modelo

Fonte: Elaborado pelos autores (2026)

Conclusões e próximos passos

O modelo LSTM desenvolvido atingiu R² ≥ 0,79 e MAPE ≈ 11,4% nos dois edifícios, com diferença de apenas 1,2 pontos percentuais em relação ao benchmark de Mariano-Hernández et al. (2021).

Resultado obtido com uma única arquitetura e poucos ajustes de hiperparâmetros, aplicada a perfis de uso distintos, o que evidencia a capacidade de generalização do modelo. Os resíduos de predição estabelecem os limiares iniciais para detecção de anomalias, confirmando a viabilidade da abordagem proposta.

Próximos passos: Ajuste de hiperparâmetros; Comparação com outros modelos; Experimentos com modelos ensemble; Detecção de anomalias por resíduos.

Referências

MARIANO-HERNÁNDEZ, D. et al. A Data-Driven Forecasting Strategy to Predict Continuous Hourly Energy Demand in Smart Buildings. Applied Sciences, v. 11, n. 17, p. 7886, ago. 2021.

NASA. NASA Prediction of Worldwide Energy Resources — NASA POWER. Washington, DC: NASA, 2025.