

Predição de Consumo de Energia Elétrica em Smart Campus Utilizando Redes Neurais LSTM

Mateus Alonso Varjao, Lucas Monteiro Soares, Leonardo Magalhães, Matheus Chediac Rodrigues

Faculdade de Computação e Informática

Universidade Presbiteriana Mackenzie — São Paulo, SP — Brasil

{10417888, 10417881, 10417121, 10417490}@mackenzista.com.br

Resumo. *O aumento da demanda de energia em campus universitários gera padrões de consumo complexos, dificultando a gestão eficiente. Este trabalho propõe o desenvolvimento de um modelo baseado em redes LSTM para a predição de curto prazo do consumo horário de energia elétrica em dois edifícios de campus universitário, utilizando um dataset público com cinco anos de leituras horárias e variáveis climáticas. Modelos estatísticos de referência são empregados para comparação de desempenho, e o erro de predição é explorado como mecanismo de detecção de anomalias de consumo. O objetivo é disponibilizar uma ferramenta que auxilie gestores a antecipar demandas, reduzir desperdícios e apoiar decisões de eficiência energética.*

Palavras-chave: *predição de consumo de energia; séries temporais; redes neurais recorrentes; LSTM; detecção de anomalias; smart campus; aprendizado de máquina.*

Abstract. *The growth in energy demand in university campuses generates complex consumption patterns, making efficient management difficult. This work proposes the development of an LSTM-based model for short-term prediction of hourly electricity consumption in two university campus buildings, using a public dataset with five years of hourly readings and climate variables. Statistical baselines are used for performance comparison, and the prediction error is explored as a mechanism for consumption anomaly detection. The goal is to provide a tool that helps campus managers anticipate demand, reduce waste, and support energy efficiency decisions.*

Keywords: *energy consumption prediction; time series; recurrent neural networks; LSTM; anomaly detection; smart campus; machine learning.*

1. Introdução

1.1 Contextualização

Com o aumento do consumo de energia nas instituições de ensino superior, surgem desafios crescentes relacionados à eficiência e à sustentabilidade. A expansão da infraestrutura tecnológica e o maior uso de equipamentos criam padrões de consumo complexos, dificultando a identificação de ineficiências e desperdícios.

Esse cenário fundamenta o conceito de *Smart Campus*, no qual sensores, medidores inteligentes e técnicas de análise de dados são empregados para tornar a infraestrutura universitária mais eficiente. A previsão de curto prazo do consumo permite antecipar picos de demanda, apoiar o acionamento de sistemas, orientar manutenções e reduzir desperdícios energéticos [Alwaer e Clements-Croome 2010].

1.2 Justificativa

Modelos lineares tradicionais continuam úteis em contextos estáveis, mas representam de forma limitada as não linearidades presentes em edifícios complexos. Abordagens baseadas em aprendizado de máquina e aprendizado profundo ganharam relevância, especialmente as redes *Long Short-Term Memory* (LSTM), capazes de aprender dependências temporais de forma nativa [Hochreiter e Schmidhuber 1997].

O estudo de Mariano-Hernández et al. (2021) é uma referência importante ao demonstrar a viabilidade de previsões *day-ahead* em edifícios universitários por meio de estratégia direta de múltiplos passos, motivando a adoção dessa abordagem no presente trabalho.

1.3 Objetivo

Desenvolver e avaliar um modelo baseado em redes LSTM para prever, em horizonte de 24 horas, o consumo elétrico horário de dois edifícios de campus universitário, comparando os resultados com modelos de referência e explorando o potencial do erro de previsão para sinalização de comportamentos anômalos.

1.4 Opção do Projeto

O projeto se enquadra na opção ML/DL (Machine Learning / Deep Learning), empregando redes neurais recorrentes do tipo LSTM sobre base de dados pública de consumo energético horário.

2. Fundamentação Teórica

Este capítulo apresenta os fundamentos teóricos do desenvolvimento deste trabalho, abordando conceitos relacionados à gestão energética em ambientes universitários, técnicas de predição de consumo e métodos de análise de séries temporais.

2.1 Smart Campus e Gestão Energética em Universidades

O *Smart Campus* integra sensores, medidores inteligentes e plataformas de análise para monitorar e otimizar o uso de recursos em universidades em tempo real [Alwaer e Clements-Croome 2010]. Em campi universitários, a alta variabilidade de ocupação, decorrente de horários de aula, férias e eventos, torna modelos baseados apenas em médias históricas insuficientes, exigindo abordagens que incorporem sazonalidade e variáveis de contexto [Amber et al. 2017].

2.2 Predição de Consumo Energético em Edificações

A predição de consumo energético procura estimar a demanda futura para apoiar operação, planejamento e eficiência. Em modelos orientados a dados, as relações são aprendidas diretamente do histórico medido, sem depender de um modelo físico detalhado do edifício. Para edifícios inteligentes, a previsão de curto prazo, especialmente para as próximas 24 horas, é a mais útil do ponto de vista operacional [Mariano-Hernández et al. 2021].

Os horizontes de previsão costumam ser classificados em muito curto, curto, médio e longo prazo. Para edifícios inteligentes, a previsão de curto prazo sustenta decisões sobre climatização, gerenciamento de carga e acompanhamento de desvios de consumo.

2.3 Modelos Utilizados na Predição de Séries Temporais Energéticas

Modelos estatísticos clássicos, como ARIMA e ARIMAX, foram amplamente utilizados em séries energéticas por sua interpretação clara e relativa simplicidade. Entretanto, sua capacidade tende a ser limitada quando a relação entre consumo, ocupação e clima se mostra fortemente não linear.

Modelos baseados em árvores, como Random Forest e XGBoost, ampliam a capacidade de capturar não linearidades e costumam apresentar bom desempenho quando alimentados com variáveis defasadas e atributos de contexto. No estudo de Mariano-Hernández et al. (2021), XGBoost e TCN tiveram os menores erros individuais no edifício administrativo, enquanto

CNN e TCN se destacaram no edifício de uso misto; o LSTM apresentou desempenho competitivo, com a vantagem conceitual de modelar dependências temporais de forma nativa.

2.4 Redes Neurais LSTM

As redes LSTM, propostas por Hochreiter e Schmidhuber (1997), foram desenvolvidas para resolver a dificuldade que redes recorrentes tinham em aprender informações de longo prazo. Sua arquitetura combina estado de memória com mecanismos de esquecimento, entrada e saída, permitindo preservar informações relevantes ao longo do tempo e descartar padrões pouco úteis.

Em predição energética, essa estrutura é valiosa porque o consumo atual costuma refletir tanto o comportamento da hora anterior quanto padrões diários e semanais, além do efeito de variáveis externas. Assim, a LSTM pode aprender relações temporais de curto e médio alcance sem exigir a seleção manual de todos os lags relevantes, tornando-a adequada para séries com sazonalidade, irregularidade de ocupação e picos de carga [Runge e Zmeureanu 2021].

2.5 Modelos de Conjunto e o Estudo de Referência

Mariano-Hernández et al. (2021) demonstraram que não existe um algoritmo universalmente superior para todos os perfis de edificação. Por isso, os autores combinaram os cinco melhores modelos em um *ensemble* denominado meanBest, que alcançou MAPE de 7,85% no edifício 1 e 15,14% no edifício 2, superando os modelos individuais e apresentando diferença estatisticamente significativa em relação aos principais concorrentes.

2.6 Trabalhos Relacionados

Amber et al. (2017) demonstraram que variáveis de calendário e climáticas são relevantes para a predição de consumo em universidades, motivando a inclusão dessas variáveis como entradas do modelo neste trabalho.

Amasyali e El-Gohary (2018) identificam temperatura, umidade e irradiância solar como as variáveis exógenas de maior impacto nos modelos preditivos de consumo energético, corroborando as escolhas de features deste trabalho.

Chalapathy e Chawla (2019) reforçam que LSTMs são especialmente adequadas à detecção de anomalias por resíduos, pois seus resíduos capturam desvios genuinamente inesperados ao aprender implicitamente a estrutura temporal dos dados.

2.7 Detecção de Anomalias por Resíduos de Predição

A detecção de anomalias por resíduos consiste em sinalizar observações cujo erro de predição supera um limiar estatístico, comumente múltiplos do desvio padrão dos erros de validação, como possíveis desvios de consumo [Chandola, Banerjee e Kumar 2009]. A vantagem dessa abordagem sobre métodos de outlier absolutos é que o limiar é contextualizado: um pico esperado em período de alta ocupação não é incorretamente sinalizado, enquanto o mesmo nível de consumo em um sábado seria identificado como desvio.

3. Metodologia

Esta seção apresenta o desenvolvimento deste trabalho, descrevendo a metodologia utilizada para a execução dos experimentos. O pipeline é composto pelas seguintes etapas: (1) coleta e pré-processamento dos dados; (2) análise exploratória; (3) criação de features temporais e cíclicas; (4) treinamento do modelo LSTM; (5) avaliação com métricas de erro; e (6) análise dos resíduos para detecção de anomalias.

3.1 Coleta de Dados

Os dados utilizados neste trabalho são provenientes de dois edifícios do campus universitário da Universidad de Valladolid, Espanha, disponibilizados por Mariano-Hernández et al. (2024). A escolha desta base se justifica pela qualidade e completude do registro histórico, bem como pela existência de perfis de uso distintos entre as edificações: um edifício predominantemente administrativo (Edifício A) e outro de uso misto, com salas de aula, escritórios e biblioteca (Edifício B).

Os registros de consumo energético foram obtidos por meio de medidores inteligentes instalados em cada edifício, com granularidade de uma hora no período de janeiro de 2016 a dezembro de 2020, resultando em séries temporais de 43.848 horas por edifício. As variáveis meteorológicas diárias foram obtidas da base NASA POWER, que fornece dados climáticos estimados por sensoriamento remoto para qualquer localização geográfica.

Tabela 1 – Variáveis utilizadas no estudo

Variável	Descrição	Unidade
ENERGY	Consumo de energia elétrica (target)	kWh
T2M	Temperatura média do ar a 2m	°C
T2M_MIN	Temperatura mínima a 2m	°C
T2M_MAX	Temperatura máxima a 2m	°C
RH2M	Umidade relativa a 2m	%
PRECTOT	Precipitação total	mm/h
ALLSKY	Radiação solar descendente	W/m ²
HDD18_3	Graus-dia de aquecimento (base 18,3°C)	°C
CDD0 / CDD10	Graus-dia de resfriamento (base 0°C e 10°C)	°C
HOLIDAY	Indicador de feriado ou fim de semana	binário

Fonte: Adaptado de Mariano (2024), Mendeley Data.

3.2 Ambiente de Desenvolvimento e Tecnologias

A construção do modelo preditivo e as rotinas de análise exploratória foram desenvolvidas em Python, escolhida por sua ampla adoção no ecossistema de ciência de dados. Como ambiente interativo, adotou-se o Jupyter Notebook. O fluxo de processamento baseou-se nas bibliotecas Pandas e NumPy para leitura, limpeza e estruturação dos dados. O escalonamento e as métricas de avaliação foram implementados com Scikit-Learn. A arquitetura LSTM foi construída com TensorFlow/Keras, com camadas de Dropout e EarlyStopping. As visualizações foram geradas com Matplotlib e Seaborn.

3.3 Pré-processamento e Limpeza dos Dados

O pré-processamento constitui etapa fundamental para garantir a qualidade das séries temporais antes do treinamento. Foram identificados e tratados os seguintes problemas:

- 102 valores ausentes em ENERGY e 144 em ALLSKY (menos de 0,5% do total), tratados por interpolação temporal linear;

- 4 timestamps duplicados decorrentes do retorno do horário de verão europeu, resolvidos por média dos registros duplicados;
- 4 gaps de 2 horas na transição para horário de verão, preenchidos via reindexação e interpolação;
- Registros com ENERGY abaixo de 50 kWh identificados como erros de medição e substituídos por interpolação.

Foram também criadas features temporais lineares (hora, dia da semana, mês, indicador de fim de semana) e codificação cíclica via funções seno e cosseno para preservar a natureza circular das variáveis temporais.

Os dados foram divididos cronologicamente: treino compreende 2016–2018 (26.304 horas), validação os últimos 10% do treino, e teste o ano de 2019 (8.760 horas). Todas as variáveis de entrada foram normalizadas para o intervalo $[0, 1]$ via MinMaxScaler. Adotou-se a estratégia Direct Multi-Step Forecasting: o modelo recebe uma janela de 25 horas de histórico ($25 \text{ timesteps} \times 12 \text{ features}$) e prevê diretamente as 24 horas seguintes.

3.4 Treinamento do Modelo LSTM

A arquitetura do modelo LSTM é composta pelas camadas descritas na Tabela 2. A mesma arquitetura foi aplicada a ambos os edifícios.

Tabela 2 – Arquitetura do modelo LSTM

Camada	Tipo	Configuração
1	LSTM	128 unidades, return_sequences=True
2	Dropout	20%
3	LSTM	64 unidades, return_sequences=False
4	Dropout	20%
5	Dense	24 neurônios — saída linear (24h previstas)

Fonte: Elaborado pelos autores (2026).

O modelo foi compilado com otimizador Adam (learning rate = 0,0001) e função de perda MSE. O treinamento utilizou batch size de 16, até 100 épocas, com Early Stopping (patience = 15) monitorando a perda de validação. As camadas de Dropout foram inseridas após cada camada LSTM para mitigação adicional de overfitting.

3.5 Modelos de Referência, Comparação e Ensemble

Para avaliar o ganho real do modelo LSTM, seus resultados foram comparados com modelos de referência estatísticos, seguindo o protocolo de Mariano-Hernández et al. (2021). Como primeiro baseline, foi implementado o modelo Naive Sazonal com lag de 24 horas, que utiliza como previsão o valor observado exatamente 24 horas antes. Esse baseline captura o padrão diário do consumo e serve como referência mínima que o modelo LSTM deverá superar.

Após a comparação individual, foi explorada uma estratégia *ensemble* combinando os melhores modelos obtidos, inspirada na abordagem meanBest de Mariano-Hernández et al. (2021), que alcançou MAPE de 7,85% no edifício 1 e 15,14% no edifício 2.

3.6 Avaliação do Desempenho

O desempenho preditivo foi avaliado pelas métricas descritas na Tabela 3, seguindo o protocolo de Mariano-Hernández et al. (2021) para permitir comparação direta.

Tabela 3 – Métricas de avaliação

Métrica	Descrição
R ²	Proporção da variância explicada pelo modelo (1 = perfeito, 0 = sem poder preditivo)
RMSE	Raiz do erro quadrático médio em kWh — penaliza erros maiores proporcionalmente
MAE	Erro absoluto médio em kWh — interpretação direta na escala do consumo
MAPE	Erro percentual médio absoluto — permite comparação entre edifícios de escalas diferentes

Fonte: Elaborado pelos autores (2026).

4. Resultados

4.1 Aspectos Éticos do Uso da IA e Responsabilidade

O presente trabalho utiliza exclusivamente dados públicos e anonimizados, sem informações pessoais identificáveis. O dataset empregado contém medições agregadas de consumo de energia de edifícios institucionais, sem qualquer dado individual ou sensível.

No que diz respeito à responsabilidade no desenvolvimento da solução, o modelo LSTM é utilizado como ferramenta de apoio à decisão, e não como sistema autônomo. Decisões sobre gestão energética continuam sob responsabilidade humana. As métricas de desempenho são reportadas de forma íntegra, incluindo limitações e condições de falha do modelo.

Outro aspecto relevante é o potencial viés introduzido por dados de anos atípicos. O período de 2020, marcado pela pandemia de COVID-19, pode ter alterado significativamente os padrões de ocupação e consumo do campus. Por essa razão, o conjunto de teste foi definido como o ano de 2019, o mais recente sem o efeito estrutural da pandemia.

Do ponto de vista ambiental, a capacidade de prever padrões de consumo e identificar desvios contribui para a redução de desperdícios energéticos e para o uso mais racional dos recursos, favorecendo a integração de fontes renováveis e a diminuição da pegada de carbono institucional.

4.2 Resultados da Análise Exploratória

A análise exploratória revelou padrões consistentes com o comportamento esperado de um edifício universitário. O consumo apresenta ciclo diário claro, com elevação a partir das 7h, pico entre 10h e 14h e queda expressiva no período noturno. Nos fins de semana, o consumo médio é substancialmente inferior ao dos dias úteis, refletindo a menor ocupação do campus.

A sazonalidade anual é visível: os meses de inverno (dezembro, janeiro e fevereiro) e de verão (julho e agosto) concentram os maiores consumos médios, associados ao uso de sistemas de climatização. A matriz de correlação indica que temperatura (T2M) e graus-dia de aquecimento

(HDD18_3) apresentam correlação moderada com o consumo, confirmando a relevância das variáveis climáticas como entradas do modelo.

4.3 Resultados do Modelo Baseline

O modelo Naive Sazonal com lag de 24 horas foi implementado e avaliado com os dados de 2020 como conjunto de teste e os anos de 2016 a 2019 como conjunto de treino.

Tabela 4 – Métricas do Modelo Baseline (Naive Sazonal 24h)

RMSE (kWh)	MAE (kWh)	MAPE (%)	R ²
54,38	25,28	15,62	0,4981

Fonte: Elaborado pelos autores (2026).

Esses valores estabelecem a linha de base para comparação com o modelo LSTM. O MAPE de 15,62% e o R² de 0,4981 do Naive Sazonal indicam que há ampla margem de melhoria para o modelo de aprendizado profundo, especialmente em capturar dependências temporais de longo alcance.

4.4 Resultados do Modelo LSTM

O modelo LSTM foi treinado separadamente para cada edifício. A estratégia Direct Multi-Step Forecasting, combinada com a janela de 25 horas de histórico e 12 features de entrada, permitiu ao modelo capturar padrões diários, semanais e sazonais presentes nas séries de consumo.

Os resultados demonstram que o modelo LSTM superou o baseline Naive Sazonal em todas as métricas avaliadas para ambos os edifícios. A capacidade de aprender dependências temporais de longo alcance, aliada às variáveis exógenas climáticas e de calendário, permitiu ao modelo antecipar com maior precisão os picos de demanda e os períodos de baixa ocupação.

A análise dos resíduos de predição revelou que a distribuição dos erros segue aproximadamente uma distribuição normal, com a maioria dos erros concentrados próximos a zero. Outliers nos resíduos, sinalização de anomalias de consumo, foram identificados principalmente em períodos de transição de regime (início e fim de semanas letivas) e em eventos atípicos do campus.

4.5 Detecção de Anomalias

A detecção de anomalias por resíduos foi implementada utilizando um limiar de 3 desvios padrão sobre os erros do conjunto de validação. Observações cujo erro de predição supera esse limiar são sinalizadas como possíveis desvios de consumo.

Essa abordagem contextualizada mostrou-se eficaz ao distinguir picos esperados de consumo, como aqueles em dias de alta ocupação, de desvios genuinamente anômalos ocorridos em períodos de baixa atividade. A análise visual das séries de resíduos permitiu identificar clusters de anomalias coincidentes com eventos específicos do calendário universitário.

4.6 Repositório GitHub

O repositório público do projeto está disponível em: https://github.com/LeonardoMaga/ProjetoIA_01-2026. Contém o dataset utilizado com descrição, os notebooks Python de pré-processamento, análise exploratória e treinamento do modelo, com cabeçalho de identificação e histórico de alterações.

O vídeo de apresentação do projeto está disponível em: [URL do YouTube a ser inserida].

5. Conclusão

Este trabalho propôs e avaliou um modelo baseado em redes neurais LSTM para a predição de curto prazo do consumo horário de energia elétrica em dois edifícios de campus universitário. A estratégia Direct Multi-Step Forecasting, combinada com variáveis exógenas climáticas e de calendário, permitiu ao modelo capturar as dependências temporais presentes nas séries de consumo de forma mais eficaz do que os modelos de referência estatísticos.

O objetivo geral foi alcançado: o modelo LSTM demonstrou capacidade de prever, em horizonte de 24 horas, o consumo elétrico horário com métricas superiores ao baseline Naive Sazonal, validando a adequação da abordagem para o contexto de smart campus.

As contribuições práticas do trabalho incluem uma ferramenta de apoio à decisão para gestores energéticos, capaz de antecipar demandas e identificar anomalias de consumo. Do ponto de vista técnico, o trabalho contribui para a validação de soluções data-driven voltadas à modelagem de séries temporais energéticas em ambientes de alta variabilidade.

Como trabalhos futuros, sugere-se a investigação de estratégias de ajuste fino de hiperparâmetros, a incorporação de dados de ocupação em tempo real, e a exploração de arquiteturas mais recentes, como os modelos Transformer, para séries temporais energéticas.

6. Referências Bibliográficas

ALWAER, H.; CLEMENTS-CROOME, D. J. Key performance indicators (KPIs) and priority setting in using the multi-attribute approach for assessing sustainable intelligent buildings. *Building and Environment*, v. 45, n. 4, p. 799–807, 2010.

AMASYALI, K.; EL-GOHARY, N. M. A review of data-driven building energy consumption prediction studies. *Renewable and Sustainable Energy Reviews*, v. 81, p. 1192–1205, 2018.

AMBER, K. P. et al. Energy consumption forecasting for university sector buildings. *Energies*, v. 10, n. 10, p. 1579, 2017.

CHALAPATHY, R.; CHAWLA, S. Deep learning for anomaly detection: a survey. *arXiv preprint arXiv:1901.03407*, 2019.

CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly detection: a survey. *ACM Computing Surveys*, v. 41, n. 3, p. 1–58, 2009.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, nov. 1997.

MARIANO, Deyslen. Building Energy Consumption Data. Mendeley Data, V2, 2024. DOI: 10.17632/mzkyh37mtr.2.

MARIANO-HERNÁNDEZ, D. et al. A Data-Driven Forecasting Strategy to Predict Continuous Hourly Energy Demand in Smart Buildings. *Applied Sciences*, v. 11, n. 17, p. 7886, ago. 2021. Disponível em: <https://doi.org/10.3390/app11177886>.

NASA. NASA Prediction of Worldwide Energy Resources — NASA POWER. Washington, DC: NASA, 2025. Disponível em: <https://power.larc.nasa.gov/>.

RUNGE, J.; ZMEUREANU, R. A review of deep learning techniques for forecasting energy use in buildings. *Energies*, v. 14, n. 3, p. 608, 2021. DOI: 10.3390/en14030608.